

Model Prediksi Produksi Pertanian Berbasis *Machine learning* dan Data Lapangan

Khaidir¹, Fadhlani², Zurrahmi Wirda³, Almuna Ramadhani⁴
^{1,2,3,4} Program Studi Agroekoteknologi, Universitas Malikussaleh
Kampus Utama Cot Tengku Nie Reuleut, Muara Batu, Aceh Utara
Correponding author : fadh.liani@unimal.ac.id

Abstrak

Ketidakpastian produksi pertanian merupakan tantangan krusial yang memengaruhi ketahanan pangan dan kesejahteraan petani di Indonesia. Penelitian ini bertujuan mengembangkan model prediksi produksi pertanian berbasis *machine learning* menggunakan data lapangan yang komprehensif. Data dikumpulkan dari lahan pertanian di Kota Lhokseumawe dan Kabupaten Aceh Utara selama tiga musim tanam, mencakup parameter tanah, iklim mikro, praktik budidaya, dan hasil panen aktual, dengan total 432 observasi. Empat algoritma *machine learning* dibandingkan, yaitu *Random Forest*, *Support Vector Regression*, *XGBoost*, dan *Artificial Neural Network*. Hasil penelitian menunjukkan bahwa *XGBoost* memberikan performa terbaik dengan nilai R^2 sebesar 0,89 dan RMSE 0,52 ton/ha pada dataset pengujian. Validasi lapangan pada musim tanam berikutnya mengonfirmasi kemampuan generalisasi model dengan RMSE 0,61 ton/ha. Analisis interpretabilitas model mengidentifikasi dosis pupuk nitrogen, kandungan C-organik tanah, dan curah hujan sebagai faktor paling berpengaruh terhadap produksi, dengan hubungan non-linear yang menunjukkan ambang optimal curah hujan pada kisaran 1.800–2.200 mm per musim tanam. Hasil penelitian ini menunjukkan bahwa integrasi *machine learning* dan data lapangan mampu menghasilkan prediksi produksi yang akurat dan relevan untuk mendukung pengambilan keputusan dalam sistem pertanian Indonesia.

Kata kunci: prediksi pertanian; *machine learning*; *XGBoost*; data lapangan; pertanian presisi; interpretabilitas model

Abstract

Uncertainty in agricultural production remains a critical challenge affecting food security and farmers' livelihoods in Indonesia. This study aims to develop an accurate agricultural production prediction model using *machine learning* based on comprehensive field-level data. Data were collected from agricultural fields in Lhokseumawe City and North Aceh Regency over three consecutive growing seasons, covering soil properties, microclimatic conditions, cultivation practices, and actual crop yields, resulting in a total of 432 observations. Four *machine learning* algorithms were evaluated and compared, namely *Random Forest*, *Support Vector Regression*, *XGBoost*, and *Artificial Neural Networks*. The results demonstrate that *XGBoost* achieved the best performance, with an R^2 value of 0.89 and an RMSE of 0.52 t ha⁻¹ on the test dataset. Field validation conducted in the subsequent growing season confirmed the model's generalization capability, yielding an RMSE of 0.61 t ha⁻¹.

Model interpretability analysis identified nitrogen fertilizer application, soil organic carbon content, and rainfall as the most influential predictors of crop production, exhibiting non-linear relationships with an optimal rainfall range of 1,800–2,200 mm per growing season. Overall, this study demonstrates that integrating *machine learning* with high-resolution field data can produce accurate and interpretable production forecasts, providing a robust decision-support basis for improving agricultural efficiency and resilience in heterogeneous farming systems.

Keywords: agricultural yield prediction; *machine learning*; XGBoost; field data; precision agriculture; model interpretability

1. PENDAHULUAN

Sektor pertanian Indonesia menghadapi tantangan yang semakin kompleks dalam mempertahankan produktivitas di tengah dinamika perubahan iklim, tekanan konversi lahan, dan meningkatnya tuntutan ketahanan pangan nasional (Faoziyah *et al.*, 2024). Ketidakpastian hasil panen menjadi permasalahan krusial yang berdampak langsung pada kesejahteraan petani, stabilitas ekonomi regional, serta kemampuan pemerintah dalam merancang kebijakan pangan yang responsif, sambil mempertimbangkan faktor lingkungan dan sosial yang memengaruhi produksi pertanian (Antriandarti *et al.*, 2024; Ansari *et al.*, 2023).

Studi menunjukkan bahwa sebagian besar wilayah masih rentan terhadap fluktuasi produksi pangan, sementara ketergantungan pada impor pangan tetap tinggi, sehingga memperkuat urgensi pengembangan inovasi teknologi pertanian, intensifikasi produksi tanpa ekspansi lahan, dan intervensi kebijakan yang komprehensif untuk meningkatkan ketahanan pangan nasional (Desta, 2025). Selain itu, adaptasi praktik pertanian berbasis data dan peningkatan peran petani, termasuk perempuan, dalam pengelolaan produksi dan ketahanan pangan rumah tangga, menjadi strategi penting untuk mengurangi risiko gagal panen dan memperkuat ketahanan pangan lokal (Adisu Mekonnen *et al.*, 2020; A. Diallo *et al.*, 2020).

Dalam konteks ini, kemampuan memprediksi produksi pertanian secara akurat merupakan elemen strategis, tidak hanya untuk mendukung perencanaan budidaya di tingkat petani, tetapi juga sebagai dasar pengambilan keputusan pada skala wilayah dan nasional (Nyéki & Neményi, 2022; Trachenko *et al.*, 2018; Hajimirzajan *et al.*, 2021; Zhang *et al.*, 2019). Prediksi hasil tanaman memungkinkan pengelolaan sumber daya secara efisien dan mitigasi risiko terkait fluktuasi iklim. Selain itu, pendekatan berbasis data mendukung optimalisasi alokasi tanaman dan peningkatan pendapatan petani.

Seiring dengan perkembangan transformasi digital, pendekatan pengelolaan pertanian berbasis data semakin mendapat perhatian baik dalam penelitian maupun

praktik. Kemajuan teknologi komputasi, ketersediaan big data, serta integrasi artificial intelligence (AI) memungkinkan pengolahan dan analisis informasi pertanian secara lebih sistematis dan terukur dibandingkan metode tradisional (Fountas *et al.*, 2020). Pendekatan ini juga membuka peluang untuk pengambilan keputusan yang lebih tepat dan efisien dalam pengelolaan sumber daya pertanian (Chergui & Kechadi, 2022).

Dalam satu dekade terakhir, *machine learning* sebagai cabang AI muncul sebagai pendekatan yang menjanjikan dalam prediksi produksi pertanian karena kemampuannya menangkap hubungan non-linear dan kompleks antarvariabel yang sulit dimodelkan menggunakan metode statistik konvensional (Sudduth *et al.*, 2020). Berbagai algoritma *machine learning* telah diaplikasikan dalam konteks pertanian – mulai dari prediksi hasil panen, pemantauan kondisi tanaman, hingga optimalisasi penggunaan input produksi – dengan tingkat akurasi yang relatif tinggi dalam studi empiris terkini (Elbasi *et al.*, 2023; Araújo *et al.*, 2023).

Meskipun demikian, efektivitas model prediksi berbasis *machine learning* sangat bergantung pada kualitas, granularitas, dan relevansi data yang digunakan. Sebagian besar penelitian pertanian masih mengandalkan data sekunder seperti citra satelit, data meteorologi regional, atau statistik produksi agregat. Temuan lintas bidang menunjukkan bahwa keterbatasan data – dari ketersediaan hingga konsistensi – menjadi hambatan utama dalam implementasi ML yang efektif (Tercan & Meisen, 2022; Tamagusko & Ferreira, 2023; Strielkowski *et al.*, 2023). Oleh karena itu, pengembangan dataset yang lebih lengkap, berkualitas, dan terstandarisasi menjadi langkah krusial bagi keberhasilan prediksi pertanian berbasis *machine learning*.

Pendekatan ini memiliki keunggulan dari sisi cakupan spasial yang luas, namun sering kali kurang mampu merepresentasikan variabilitas kondisi lapangan yang bersifat mikro. Faktor-faktor seperti karakteristik tanah, praktik budidaya spesifik, sistem irigasi, serta varietas tanaman yang digunakan petani memiliki pengaruh signifikan terhadap produktivitas, tetapi kerap tereduksi atau bahkan terabaikan dalam data agregat yang umum digunakan dalam model prediksi.

Keterbatasan tersebut menunjukkan adanya kesenjangan penelitian antara pengembangan model prediksi berbasis *machine learning* dan realitas praktik pertanian di lapangan, khususnya dalam konteks pertanian Indonesia yang sangat heterogen. Masih relatif sedikit studi yang menjadikan data lapangan sebagai sumber utama dalam pengembangan model prediksi, padahal data tersebut berpotensi memberikan informasi yang lebih akurat dan kontekstual. Akibatnya, banyak model yang secara statistik menunjukkan performa baik secara teoritis, namun kurang aplikatif ketika diterapkan pada skala operasional petani.

Penelitian ini bertujuan mengembangkan model prediksi produksi pertanian berbasis *machine learning* dengan memanfaatkan data lapangan sebagai fondasi utama. Data lapangan yang dikumpulkan secara langsung diharapkan merepresentasikan kondisi biofisik dan praktik budidaya secara realistis, sehingga model yang dihasilkan relevan dan aplikatif di konteks lokal pertanian Indonesia. Kontribusi utama penelitian terletak pada integrasi *machine learning* dengan data lapangan yang detail untuk menghasilkan prediksi produksi yang lebih akurat, transparan, dan mendukung pengambilan keputusan berbasis data.

2. METODOLOGI PENELITIAN

Penelitian ini menggunakan pendekatan kuantitatif dengan desain studi lapangan longitudinal yang dikombinasikan dengan pemodelan *machine learning*. Pengumpulan data dilakukan pada lahan pertanian di dua wilayah dengan karakteristik agroekologi berbeda, yaitu Kota Lhokseumawe dan Kabupaten Aceh Utara, yang merepresentasikan dataran rendah, menengah, dan tinggi. Observasi dilakukan selama tiga musim tanam berturut-turut untuk menangkap variabilitas temporal dan meningkatkan representativitas data.

Data yang dikumpulkan mencakup parameter tanah (pH, kandungan N, P, K, C-organik, dan tekstur), data iklim mikro (curah hujan, suhu, kelembaban, dan radiasi matahari), praktik budidaya (jenis dan dosis pupuk, irigasi, penggunaan pestisida, dan varietas tanaman), serta parameter biofisik tanaman pada berbagai fase pertumbuhan. Produksi aktual diukur menggunakan metode ubinan dengan luas minimal 5 m² per plot dan replikasi dilakukan sebanyak tiga kali. Seluruh data dikompilasi ke dalam basis data terstruktur dengan total 432 observasi plot-musim tanam.

Tahap pra-pemrosesan data meliputi penanganan nilai hilang, deteksi dan perlakuan outlier, serta normalisasi fitur numerik. Feature engineering dilakukan untuk menghasilkan variabel turunan yang relevan secara agronomis, seperti Growing Degree Days dan indeks keseimbangan air. Dataset kemudian dibagi menjadi data pelatihan, validasi, dan pengujian untuk memastikan evaluasi model yang objektif dan menghindari overfitting.

Empat algoritma *machine learning* diuji dan dibandingkan, yaitu *Random Forest*, *Support Vector Regression*, *Extreme Gradient Boosting (XGBoost)*, dan *Artificial Neural Network*. Optimasi hyperparameter dilakukan menggunakan skema cross-validation. Performa model dievaluasi menggunakan metrik RMSE (*Root Mean Squared Error*), MAE (*Mean Absolute Error*), MAPE (*Mean Absolute Percentage Error*), dan koefisien determinasi (R^2).

Interpretabilitas model dianalisis menggunakan SHAP (*SHapley Additive exPlanations*) untuk mengidentifikasi kontribusi relatif setiap variabel input terhadap prediksi produksi.

Model terbaik selanjutnya diuji menggunakan dataset independen serta divalidasi pada musim tanam berikutnya di lokasi yang berbeda untuk menilai kemampuan generalisasi model dalam kondisi lapangan. Sebagai tahap akhir, model dikembangkan dalam bentuk prototipe antarmuka pendukung keputusan untuk memfasilitasi pemanfaatan hasil prediksi secara praktis.

3. HASIL DAN PEMBAHASAN


Dataset penelitian terdiri atas 432 observasi plot-musim tanam yang mencakup variasi agroekologi dataran rendah, menengah, dan tinggi di Kota Lhokseumawe dan Kabupaten Aceh Utara. Variabel yang dikumpulkan mencakup karakteristik tanah, iklim mikro, praktik budidaya, serta parameter biofisik tanaman, dengan hasil panen aktual sebagai variabel target. Rentang nilai produksi cukup bervariasi, mencerminkan heterogenitas kondisi lapangan dan menyediakan dasar yang kuat untuk pengembangan model prediksi berbasis *machine learning*.

Empat algoritma *machine learning* diuji untuk memprediksi produksi pertanian, yaitu *Random Forest*, *Support Vector Regression*, *XGBoost*, dan *Artificial Neural Network*. Evaluasi pada data uji menunjukkan bahwa seluruh model mampu menangkap pola non-linear antara variabel input dan output, meskipun dengan tingkat akurasi berbeda. Model berbasis ensemble umumnya lebih stabil dibandingkan model berbasis kernel atau jaringan saraf tiruan.

Tabel 1. Kinerja model prediksi pada data uji

Model	RMSE (ton/ha)	MAE (ton/ha)	MAPE (%)	R ²
<i>Random Forest</i>	0,68	0,52	9,4	0,82
<i>Support Vector Regression</i>	0,74	0,58	10,7	0,79
<i>XGBoost</i>	0,52	0,41	7,6	0,89
<i>Artificial Neural Network</i>	0,61	0,47	8,9	0,85


Gambar 1 menunjukkan hubungan antara nilai produksi aktual dan prediksi model *XGBoost* pada data uji. Distribusi titik-titik observasi dekat garis diagonal menandakan prediksi yang akurat, dengan sedikit underpredict pada produksi tinggi dan *overpredict* pada produksi rendah.



Garis diagonal (---) menunjukkan prediksi sempurna
 $R^2 = 0.89$, RMSE = 0.52 ton/ha

Gambar 1. Scatter Plot Prediksi vs Aktual (Model XGBoost)

Analisis kontribusi variabel menggunakan *SHAP values* (Gambar 2) mengidentifikasi dosis pupuk nitrogen, kandungan C-organik tanah, dan curah hujan sebagai faktor paling berpengaruh terhadap prediksi produksi, dengan nilai kontribusi masing-masing 0,34, 0,28, dan 0,24. Variabel lain seperti dosis pupuk fosfor, pH tanah, dan dosis pupuk kalium juga memberikan pengaruh yang lebih rendah. Pola SHAP menunjukkan hubungan non-linear antara beberapa variabel kunci dan produksi, misalnya nitrogen dan curah hujan memiliki titik optimum di mana peningkatan lebih lanjut tidak menambah hasil, menandakan fenomena *diminishing returns*.



Gambar 2. SHAP Summary Plot - Feature Importance dan Dampak terhadap Prediksi

Validasi lapangan pada musim tanam berikutnya menggunakan 20 plot baru menunjukkan performa *XGBoost* tetap baik dengan RMSE = 0,61 ton/ha dan $R^2 = 0,84$, mengindikasikan kemampuan generalisasi model yang memadai terhadap kondisi nyata. Analisis sensitivitas menegaskan bahwa perubahan kecil pada variabel input kunci, khususnya nitrogen dan ketersediaan air, dapat menghasilkan variasi output yang signifikan, menunjukkan potensi model sebagai alat pendukung pengambilan keputusan dalam manajemen pemupukan dan irigasi. Implementasi prototipe aplikasi berbasis Python memungkinkan pengguna memasukkan parameter kondisi lahan dan memperoleh estimasi produksi beserta visualisasi faktor dominan yang memengaruhi hasil.

Hasil penelitian menunjukkan bahwa model *machine learning* berbasis data lapangan mampu memprediksi produksi pertanian dengan akurasi tinggi. Di antara algoritma yang diuji, *XGBoost* memberikan performa terbaik ($R^2 = 0,89$; RMSE = 0,52 ton/ha), menunjukkan kemampuannya dalam menangkap hubungan non-linear dan interaksi kompleks antarvariabel.

Analisis interpretabilitas model menunjukkan bahwa dosis pupuk nitrogen merupakan variabel paling berpengaruh terhadap produksi, diikuti oleh C-organik tanah dan curah hujan. Dominasi nitrogen konsisten dengan prinsip agronomi yang menyatakan bahwa nitrogen sering menjadi faktor pembatas utama dalam produksi padi. Dobermann dan Fairhurst (2000) melaporkan bahwa nitrogen menjelaskan sekitar 40–60% variasi hasil padi di Asia, dan temuan ini memberikan konfirmasi kuantitatif dalam konteks lokal. *Analisis partial dependence* menunjukkan adanya dosis optimum nitrogen pada kisaran 150–160 kg/ha, di mana peningkatan lebih lanjut menghasilkan *diminishing returns*, mengurangi risiko dampak lingkungan akibat overaplikasi nitrogen.

C-organik tanah muncul sebagai prediktor penting kedua yang menegaskan peran strategis bahan organik dalam meningkatkan produktivitas pertanian. Model menunjukkan bahwa peningkatan C-organik dari sekitar 1,5% menjadi 2,5% berpotensi meningkatkan produksi hingga 0,8 ton/ha. Hubungan ini dapat dijelaskan melalui perbaikan kapasitas tukar kation, retensi air, dan aktivitas mikrobiologis tanah (Oldfield *et al.*, 2018; Lal, 2020). Temuan ini sejalan dengan penelitian yang menekankan bahwa peningkatan karbon organik tanah tidak hanya mendukung mitigasi perubahan iklim, tetapi juga meningkatkan stabilitas dan produktivitas sistem pertanian (Maqbool *et al.*, 2025; Page *et al.*, 2020). Dengan demikian, pengelolaan bahan organik menjadi komponen penting dalam strategi intensifikasi berkelanjutan.

Hubungan non-linear antara curah hujan dan produksi padi memberikan bukti empiris terhadap konsep water-yield relationship (Li *et al.*, 2024; Rehman & Ahmad, 2022). Produksi optimal dicapai pada kisaran 1.800–2.200 mm per musim tanam, sementara defisit maupun surplus air berdampak negatif terhadap hasil. Curah hujan rendah menyebabkan stres air, sedangkan curah hujan berlebih meningkatkan risiko genangan, pencucian hara, dan penyakit tanaman. Temuan ini relevan dalam konteks perubahan iklim yang ditandai oleh meningkatnya variabilitas dan kejadian ekstrem curah hujan.

Perbandingan performa antar algoritma menunjukkan adanya trade-off antara akurasi, interpretabilitas, dan efisiensi komputasi. Keunggulan XGBoost terutama didukung oleh mekanisme regularisasi dan kemampuannya memodelkan interaksi kompleks antarvariabel. *Random Forest* menunjukkan performa stabil dan relatif mudah diinterpretasikan, sementara *Artificial Neural Network* belum menunjukkan keunggulan signifikan, kemungkinan akibat keterbatasan ukuran dataset.

Validasi lapangan menunjukkan bahwa model mempertahankan performa yang konsisten pada kondisi nyata, dengan peningkatan RMSE yang relatif kecil dari 0,52 menjadi 0,61 ton/ha. Hal ini mengindikasikan kemampuan generalisasi model yang baik dan relevan untuk aplikasi praktis. Perbedaan performa antar wilayah menegaskan pentingnya mempertimbangkan heterogenitas geografis dan praktik budidaya. Secara keseluruhan, hasil penelitian ini memperkuat paradigma data-driven agriculture dengan menunjukkan bahwa integrasi data lapangan dan *machine learning* mampu menghasilkan model prediksi yang akurat, *interpretable*, dan aplikatif, serta membuka peluang pengembangan lebih lanjut melalui integrasi data penginderaan jauh dan sensor IoT.

4. KESIMPULAN

Hasil penelitian model prediksi produksi pertanian berbasis *machine learning* dan data lapangan Adalah sebagai berikut :

1. Penelitian ini berhasil mengembangkan model prediksi produksi pertanian berbasis *machine learning* dan data lapangan yang akurat serta relevan untuk kondisi pertanian Indonesia. Di antara algoritma yang diuji, *XGBoost* menunjukkan performa terbaik dengan nilai R^2 sebesar 0,89 dan RMSE 0,52 ton/ha pada dataset pengujian, serta mempertahankan kinerja yang konsisten pada validasi lapangan musim tanam berikutnya (RMSE 0,61 ton/ha). Konsistensi ini mengindikasikan kemampuan generalisasi model yang baik dan menegaskan potensi penerapannya dalam konteks pertanian riil yang bersifat heterogen
2. Analisis interpretabilitas menunjukkan bahwa dosis pupuk nitrogen, kandungan C-organik tanah, dan curah hujan merupakan faktor paling berpengaruh terhadap produksi padi, dengan hubungan non-linear dan ambang optimal yang relevan secara agronomis. Temuan ini menegaskan pentingnya penggunaan data lapangan beresolusi tinggi untuk menangkap variabilitas mikro dalam sistem pertanian, sekaligus memperkuat paradigma *data-driven agriculture* yang mengintegrasikan akurasi prediksi dan interpretabilitas. Ke depan, pengembangan model dapat diarahkan pada perluasan cakupan geografis serta integrasi data penginderaan jauh dan sensor IoT guna meningkatkan *robustness* dan skalabilitas sistem prediksi pertanian.

DAFTAR PUSTAKA

- Antriyandarti, E., Suprihatin, D. N., Pangesti, A. W., & Samputra, P. L. (2024). The dual role of women in food security and agriculture in responding to climate change: Empirical evidence from Rural Java. *Environmental Challenges*, 14, 100852. <https://doi.org/10.1016/j.envc.2024.100852>.
- Araujo, S. O., Peres, R. S., Ramalho, J. C., Lidon, F., & Barata, J. (2023). *Machine learning applications in agriculture: current trends, challenges, and future perspectives*. *Agronomy*, 13(12), 2976. <https://doi.org/10.3390/agronomy13122976>.
- Chergui, N., & Kechadi, M. T. (2022). Data analytics for crop management: a big data view. *Journal of Big Data*, 9(1), 123. <https://doi.org/10.1186/s40537-022-00668-2>.
- Desta, T. T. (2025). Sustainable Intensification of Subsistence Agriculture, Socioeconomic Transformation, and Food Security. *Advances in Agriculture*, 2025(1), 6671209. <https://doi.org/10.1155/aia/6671209>.

- Diallo, A., Donkor, E., & Owusu, V. (2020). Climate change adaptation strategies, productivity and sustainable food security in southern Mali. *Climatic Change*, 159(3), 309-327. <https://doi.org/10.1007/s10584-020-02684-8>.
- Elbasi, E., Zaki, C., Topcu, A. E., Abdelbaki, W., Zreikat, A. I., Cina, E., ... & Saker, L. (2023). Crop prediction model using *machine learning* algorithms. *Applied Sciences*, 13(16), 9288. <https://doi.org/10.3390/app13169288>.
- Faoziyah, U., Rosyaridho, M. F., & Panggabean, R. (2024). Unearthing agricultural land use dynamics in Indonesia: Between food security and policy interventions. *Land*, 13(12), 2030. <https://doi.org/10.3390/land13122030>.
- Fountas, S., Espejo-García, B., Kasimati, A., Mylonas, N., & Darra, N. (2020). The future of digital agriculture: technologies and opportunities. *IT professional*, 22(1), 24-28. <https://doi.org/10.1109/MITP.2019.2963412>.
- Hajimirzajan, A., Vahdat, M., Sadegheih, A., Shadkam, E., & El Bilali, H. (2021). An integrated strategic framework for large-scale crop planning: sustainable climate-smart crop planning and agri-food supply chain management. *Sustainable production and consumption*, 26, 709-732. <https://doi.org/10.1016/j.spc.2020.12.016>.
- Lal, R. (2020). Soil organic matter and water retention. *Agronomy Journal*, 112(5), 3265-3277. <https://doi.org/10.1002/agj2.20282>.
- Li, C., Mao, X., Zheng, M., & Han, M. (2024). Adapting Seasonal Rice Cultivation Strategies for Food Security in Response to Climate Change Impacts. *Sustainability*, 16(16), 6748. <https://doi.org/10.3390/su16166748>.
- Maqbool, Z., Farooq, M. S., Rafiq, A., Uzair, M., & Hussain, Q. (2025). Utilisation of Climate-Smart Conservation Agriculture Practices for Improved Soil Carbon Sequestration, Greenhouse Gas Mitigation and Sustainable Crop Productivity. *Soil Use and Management*, 41(2), e70103. <https://doi.org/10.1111/sum.70103>.
- Mekonnen, A., Tessema, A., Ganewo, Z., & Haile, A. (2021). Climate change impacts on household food security and adaptation strategies in southern Ethiopia. *Food and Energy Security*, 10(1), e266. <https://doi.org/10.1002/fes3.266>.
- Muis, A., Suirlan, R., & Achmad, N. H. D. (2025). Analysis of Food Sovereignty in Indonesia: Macroeconomic Data. *Research on World Agricultural Economy*, 712-722. <https://doi.org/10.36956/rwae.v6i2.1675>.
- Nyéki, A., & Neményi, M. (2022). Crop yield prediction in precision agriculture. *Agronomy*, 12(10), 2460. <https://doi.org/10.3390/agronomy12102460>.
- Oldfield, E. E., Bradford, M. A., & Wood, S. A. (2019). Global meta-analysis of the relationship between soil organic matter and crop yields. *Soil*, 5(1), 15-32. <https://doi.org/10.5194/SOIL-5-15-2019>.
- Page, K. L., Dang, Y. P., & Dalal, R. C. (2020). The ability of conservation agriculture to conserve soil organic carbon and the subsequent impact on soil physical, chemical, and

- biological properties and yield. *Frontiers in sustainable food systems*, 4, 31. <https://doi.org/10.3389/fsufs.2020.00031>.
- Rehman, F. U., & Ahmad, E. (2022). The effect of climate patterns on rice productivity in Pakistan: an application of Driscoll and Kraay estimator. *Environmental Science and Pollution Research*, 29(35), 53076-53087. <https://doi.org/10.1007/s11356-022-19624-x>.
- Strielkowski, W., Vlasov, A., Selivanov, K., Muraviev, K., & Shakhnov, V. (2023). Prospects and challenges of the *machine learning* and data-driven methods for the predictive analysis of power systems: A review. *Energies*, 16(10), 4025. <https://doi.org/10.3390/en16104025>.
- Sudduth, K. A., Woodward-Greene, M. J., Penning, B. W., Locke, M. A., Rivers, A. R., & Veum, K. S. (2020). AI down on the farm. *IT Professional*, 22(3), 22-26. <https://doi.org/10.1109/MITP.2020.2986104>.
- Tamagusko, T., & Ferreira, A. (2023). *Machine learning* for prediction of the international roughness index on flexible pavements: A review, challenges, and future directions. *Infrastructures*, 8(12), 170. <https://doi.org/10.3390/infrastructures8120170>.
- Tercan, H., & Meisen, T. (2022). *Machine learning* and deep learning based predictive quality in manufacturing: a systematic review. *Journal of Intelligent Manufacturing*, 33(7), 1879-1905. <https://doi.org/10.1007/s10845-022-01963-8>.
- Tranchenko, L., Petrenko, N., Kustrich, L., Parubok, N., & Tranchenko, O. (2018). Strategic management optimization of the regional agricultural sector by means of modern forecast modeling instruments. *Problems and Perspectives in Management*, (16, Iss. 4), 64-74. [https://doi.org/10.21511/PPM.16\(4\).2018.06](https://doi.org/10.21511/PPM.16(4).2018.06).
- Zhang, Y., You, L., Lee, D., & Block, P. (2020). Integrating climate prediction and regionalization into an agro-economic model to guide agricultural planning. *Climatic Change*, 158(3), 435-451. <https://doi.org/10.1007/s10584-019-02559-7>.