

Prediksi Jumlah Produksi Tin Stabilizer Bulan Berikutnya Menggunakan XGBoost Regression

1. Pendahuluan

Penelitian ini bertujuan untuk membangun model machine learning menggunakan algoritma **Extreme Gradient Boosting (XGBoost Regression)** untuk memprediksi **jumlah produksi Tin Stabilizer pada bulan berikutnya** berdasarkan data historis produksi dan parameter hasil pengujian laboratorium (Quality Control).

Prediksi dilakukan menggunakan pendekatan **supervised learning** dengan memanfaatkan data historis perusahaan. Model mempelajari pola hubungan antara parameter kualitas produk dan data produksi pada periode sebelumnya untuk menghasilkan prediksi jumlah produksi pada periode berikutnya.

Seluruh tahapan penelitian mengikuti alur penelitian machine learning yang didukung oleh referensi jurnal ilmiah.

2. Import Library

Tujuan

Mengimpor seluruh pustaka Python yang diperlukan selama proses penelitian.

Library yang digunakan antara lain:

- pandas
- numpy
- matplotlib
- scikit-learn
- xgboost
- shap
- joblib

Alasan

Library tersebut merupakan library standar yang banyak digunakan pada penelitian machine learning berbasis data tabular.

Referensi

Chen, T., & Guestrin, C. (2016).

XGBoost: A Scalable Tree Boosting System.

3. Membaca Dataset

Dataset yang digunakan adalah

Data_Chemical_2026.04-16-MT620.xlsx

Tujuan

Membaca dataset ke dalam DataFrame agar dapat diproses.

Alasan

Tahapan ini merupakan proses awal sebelum dilakukan preprocessing.

Referensi

Kuhn, M., & Johnson, K.

Applied Predictive Modeling.

Springer.

4. Exploratory Data Analysis (EDA)

Tujuan

Memahami karakteristik dataset.

EDA meliputi

- ukuran dataset
- tipe data
- statistik deskriptif
- distribusi data
- korelasi

Alasan

EDA dilakukan agar peneliti memahami kondisi data sebelum membangun model.

Referensi

Tukey, J. W.

Exploratory Data Analysis.

1977.

5. Pemeriksaan Missing Value

Tujuan

Mengetahui apakah terdapat data kosong.

Alasan

Missing value dapat menyebabkan penurunan performa model apabila tidak ditangani dengan benar.

Referensi

Little, R. J. A., & Rubin, D. B.

Statistical Analysis with Missing Data.

6. Pemeriksaan Data Duplikat

Tujuan

Mengidentifikasi data yang muncul lebih dari satu kali.

Alasan

Data duplikat dapat menyebabkan model belajar secara bias.

Referensi

Han, Kamber & Pei.

Data Mining Concepts and Techniques.

7. Analisis Statistik Deskriptif

Menampilkan

- Mean
- Median
- Minimum
- Maximum
- Standard Deviation

Tujuan

Memahami penyebaran data.

Referensi

James et al.

An Introduction to Statistical Learning.

8. Visualisasi Distribusi Data

Visualisasi menggunakan

- Histogram
- Boxplot
- Density Plot

Alasan

Untuk mengetahui distribusi setiap parameter.

Referensi

ISLR (2021)

9. Analisis Korelasi

Menggunakan Pearson Correlation Heatmap.

Tujuan

Melihat hubungan antar variabel.

Alasan

Membantu memahami hubungan linear antar fitur.

Referensi

Benesty et al.

Pearson Correlation Coefficient.

10. Deteksi Outlier

Menggunakan metode IQR.

Alasan

Outlier dapat mempengaruhi hasil pelatihan model.

Referensi

Aggarwal C.

Outlier Analysis.

11. Feature Engineering

Tahapan ini meliputi

- Lag Feature
- Rolling Mean
- Moving Average
- Month
- Year

Tujuan

Membentuk fitur historis agar model mampu mempelajari pola produksi.

Referensi

Hyndman & Athanasopoulos.

Forecasting Principles and Practice.

12. Train-Test Split

Data dibagi berdasarkan urutan waktu.

Training :

2022–2025

Testing :

2026

Alasan

Prediksi dilakukan untuk bulan berikutnya sehingga pembagian data tidak boleh acak.

Referensi

Hyndman.

Forecasting Principles and Practice.

13. Pelatihan Model XGBoost

Menggunakan

XGBRegressor

Alasan

XGBoost mampu menangani hubungan non-linear, data tabular, serta memiliki regularisasi sehingga mengurangi overfitting.

Referensi

Chen & Guestrin (2016)

14. Hyperparameter Tuning

Menggunakan

GridSearchCV

atau

RandomizedSearchCV

Alasan

Mencari kombinasi parameter terbaik.

Referensi

Bergstra & Bengio (2012)

Random Search for Hyper-Parameter Optimization.

15. Cross Validation

Menggunakan

TimeSeriesSplit

Alasan

Karena data bersifat historis.

Referensi

scikit-learn documentation

TimeSeriesSplit.

16. Evaluasi Model

Evaluasi menggunakan

- MAE
- RMSE
- MAPE
- R^2

Alasan

Keempat metrik merupakan standar evaluasi regresi.

Referensi

Hyndman & Koehler (2006).

Another look at measures of forecast accuracy.

17. Feature Importance

Menggunakan Feature Importance bawaan XGBoost.

Tujuan

Mengetahui parameter QC yang paling mempengaruhi prediksi jumlah produksi.

Referensi

Chen & Guestrin (2016)

18. Interpretasi Model

Menggunakan

SHAP

Alasan

Memberikan interpretasi lokal maupun global terhadap model.

Referensi

Lundberg & Lee.

A Unified Approach to Interpreting Model Predictions.

NeurIPS 2017.

19. Visualisasi Hasil

Visualisasi meliputi

- Actual vs Prediction
- Residual Plot

- Feature Importance
 - SHAP Summary Plot
 - SHAP Waterfall Plot
 - Forecast Plot
-

20. Kesimpulan

Menjelaskan performa model XGBoost dalam memprediksi jumlah produksi bulan berikutnya serta mengidentifikasi parameter laboratorium yang memberikan kontribusi terbesar terhadap hasil prediksi.